

判別分析 - 考え方

数理科学統論J

(Press ? for help, n and p for next and previous slide)

村田 昇

2019.11.29

講義の予定

- **第1日: 判別分析の考え方**
- 第2日: 分析の評価

判別分析の考え方

判別分析 (discriminant analysis)

- 個体の特徴量から その個体の属するクラスを予測する関係式を構成
- 関係式: **判別関数** (discriminant function)
 - 特徴量: $X = (X_1, \dots, X_q)$
 - クラス: Y ($K(\geq 2)$ 個のラベル)
- 判別関数による分類:
 - 1次式の場合: **線形判別分析** (linear discriminant analysis)
 - 2次式の場合: **2次判別分析** (quadratic discriminant analysis)

判別分析の例

- 検査結果から患者が病気を罹患しているか判定する
 - X = 検査結果
 - Y = 病気・健康
- 今日の経済指標から明日株価が上昇するか予測する
 - X = 今日の経済指標
 - Y = 明日株価の上昇・下降
- 今日の大気の状態から, 明日の天気を予測する
 - X = 今日の大気の状態
 - Y = 晴・くもり・雨・雪

判別分析の考え方

- 確率による定式化
 - $X = x$ の下で $Y = k$ となる **条件付確率** を計算

$$p_k(x) := P(Y = k | X = x)$$

- 所属する確率が最も高いクラスに個体を分類
- 観測データ: n 個のデータ (Y, X_1, \dots, X_q)

$$\{(y_i, x_{i1}, \dots, x_{iq})\}_{i=1}^n$$

から $p_k(x)$ を構成

条件付確率

- 以下では X は離散型の q 次元確率変数で説明
- 事象 $X = \mathbf{x}$ が起きたという条件の下で 事象 $Y = k$ が起きる条件付確率

$$p_k(\mathbf{x}) = P(Y = k | X = \mathbf{x}) = \frac{P(Y = k, X = \mathbf{x})}{P(X = \mathbf{x})}$$

- (以下の議論は連続な確率変数でも成立)

条件付確率の表現

- $p_k(\mathbf{x})$ のモデル化の方針:
 - $p_k(\mathbf{x})$ を直接モデル化する (例:ロジスティック回帰)
 - $Y = k$ の下での X の条件付き確率質量関数

$$f_k(\mathbf{x}) = P(X = \mathbf{x} | Y = k) = \frac{P(X = \mathbf{x}, Y = k)}{P(Y = k)}$$

のモデル化を通じて $p_k(\mathbf{x})$ をモデル化する

- 本講義では後者について説明

事後確率による判別

ベイズの公式 (Bayes' formula)

- $f_k(\mathbf{x})$ から $p_k(\mathbf{x})$ を得る数学的原理
- 「原因 $X = \mathbf{x}$ から結果 $Y = k$ が生じる確率」を
「結果 $Y = k$ が生じたとき, 原因が $X = \mathbf{x}$ だった確率」から計算する方法
- ベイズの公式

$$P(Y = k | X = \mathbf{x}) = \frac{f_k(\mathbf{x})P(Y = k)}{\sum_{l=1}^K f_l(\mathbf{x})P(Y = l)}$$

ベイズの公式の略証

- 定義より

$$f_k(\boldsymbol{x}) = P(X = \boldsymbol{x} | Y = k) = \frac{P(X = \boldsymbol{x}, Y = k)}{P(Y = k)}$$

- 求める条件付確率:

$$P(Y = k | X = \boldsymbol{x}) = \frac{f_k(\boldsymbol{x})P(Y = k)}{P(X = \boldsymbol{x})}$$

ベイズの公式の略証 (続)

- 分母の展開:

$$\begin{aligned} P(X = \boldsymbol{x}) &= \sum_{l=1}^K P(X = \boldsymbol{x}, Y = l) \\ &= \sum_{l=1}^K f_l(\boldsymbol{x}) P(Y = l) \end{aligned}$$

事前確率と事後確率

- **事前確率** (prior probability): $\pi_k = P(Y = k)$
 - $X = x$ が与えられる前に予測されるクラス
- **事後確率** (posterior probability): $p_k(\mathbf{x})$
 - $X = x$ が与えられた後に予測されるクラス
- ベイズの公式の書き換え:

$$p_k(\mathbf{x}) = \frac{f_k(\mathbf{x})\pi_k}{\sum_{l=1}^K f_l(\mathbf{x})\pi_l}$$

(事前確率が特徴量の確率の重みで変更される)

事前確率の決め方

- 事前に特別な情報がない場合:
データから自然に決まる確率

$$\pi_k = \frac{Y = k \text{であるサンプル数}}{\text{全サンプル数}}$$

- 事前に情報がある場合:
 - 例: 身長や体重などの特徴量から喫煙者か否かを判別
 - 喫煙者の身長や体重などの特徴量を収集
 - 非喫煙者の身長や体重などの特徴量を収集
 - 事前確率は(別の調査の)日本人の喫煙者の割合を利用

線形判別分析

判別関数

- 判別の手続き
 - 特徴量 $X = \mathbf{x}$ の取得
 - 事後確率 $p_k(\mathbf{x})$ の計算
 - 事後確率最大のクラスにデータを分類
- **判別関数**: $\delta_k(\mathbf{x})$ ($k = 1, \dots, K$)

$$p_k(\mathbf{x}) < p_l(\mathbf{x}) \Leftrightarrow \delta_k(\mathbf{x}) < \delta_l(\mathbf{x})$$

事後確率の順序を保存する計算しやすい関数

- 判別関数 $\delta_k(\mathbf{x})$ を最大化するようなクラス k に分類

線形判別

- $f_k(\mathbf{x})$ の仮定:
 - q 変量正規分布の密度関数
 - 平均ベクトル $\boldsymbol{\mu}_k$: クラスごとに異なる
 - 共分散行列 Σ : すべてのクラスで共通

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{q/2} \sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k)\right)$$

- 線形判別関数: \mathbf{x} の1次式

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \Sigma^{-1} \boldsymbol{\mu}_k + \log \pi_k$$

同値性の確認

- 事後確率と判別関数の関係

$$p_k(\mathbf{x}) < p_l(\mathbf{x})$$

$$\Leftrightarrow f_k(\mathbf{x})\pi_k < f_l(\mathbf{x})\pi_l$$

$$\Leftrightarrow \log f_k(\mathbf{x}) + \log \pi_k < \log f_l(\mathbf{x}) + \log \pi_l$$

$$\Leftrightarrow -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_k) + \log \pi_k$$

$$< -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_l)^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_l) + \log \pi_l$$

$$\Leftrightarrow \delta_k(\mathbf{x}) < \delta_l(\mathbf{x})$$

平均・分散の推定

- 平均の推定 (クラスごとに行う)

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} \mathbf{x}_i$$

- 分散の推定 (まとめて行う)

$$\hat{\Sigma} = \frac{1}{n - K} \sum_{k=1}^K \sum_{i:y_i=k} (\mathbf{x}_i - \mu_k)(\mathbf{x}_i - \mu_k)^\top$$

- ただし n_k は $y_i = k$ であるようなデータの総数

R: 線形判別関数 `lda()`

- 分析を行う関数: `MASS::lda()`
- データフレームに対する分析:
 - データフレーム `mydata`: 必要な変数を含むデータフレーム
 - 列名: `x1`の変数名, ..., `xp`の変数名, `y`の変数名
- 書式は `lm()` とほぼ同じ

```
## データフレームを分析
require(MASS) # または library(MASS)
est <- lda(yの変数名 ~ x1の変数名 + ... + xpの変数名, data = mydata)
## 各クラスの判別関数値を図示
plot(est)
```

演習: 人工データによる線形判別

- 09-binary.r [🔗](#)を確認してみよう

演習: 実データによる例

- 09-weather.r  を確認してみよう

2次判別分析

2次判別

- $f_k(\mathbf{x})$ の仮定:
 - q 変量正規分布の密度関数
 - 平均ベクトル $\boldsymbol{\mu}_k$: クラスごとに異なる
 - 共分散行列 Σ_k : **クラスごとに異なる**

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{q/2} \sqrt{\det \Sigma_k}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k)\right)$$

- 2次判別関数: \mathbf{x} の2次式

$$\delta_k(\mathbf{x}) = -\frac{1}{2} \log \det \Sigma_k - \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \log \pi_k$$

同値性の確認

- 事後確率と判別関数の関係

$$p_k(\mathbf{x}) < p_l(\mathbf{x})$$

$$\Leftrightarrow f_k(\mathbf{x})\pi_k < f_l(\mathbf{x})\pi_l$$

$$\Leftrightarrow \log f_k(\mathbf{x}) + \log \pi_k < \log f_l(\mathbf{x}) + \log \pi_l$$

$$\Leftrightarrow -\frac{1}{2} \det \Sigma_k - \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k) + \log \pi_k$$
$$< -\frac{1}{2} \det \Sigma_l - \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_l)^\top \Sigma_l^{-1}(\mathbf{x} - \boldsymbol{\mu}_l) + \log \pi_l$$

$$\Leftrightarrow \delta_k(\mathbf{x}) < \delta_l(\mathbf{x})$$

平均・分散の推定

- 平均の推定 (クラスごとに行う)

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} \mathbf{x}_i$$

- 分散の推定 (クラスごとに行う)

$$\hat{\Sigma}_k = \frac{1}{n_k - 1} \sum_{i:y_i=k} (\mathbf{x}_i - \mu_k)(\mathbf{x}_i - \mu_k)^\top$$


- ただし n_k は $y_i = k$ であるようなデータの総数

R: 2次判別関数 `qda()`

- 分析を行う関数: `MASS::qda()`
- データフレームに対する分析:
 - データフレーム `mydata`: 必要な変数を含むデータフレーム
 - 列名: `x1`の変数名, ..., `xp`の変数名, `y`の変数名
- 書式は `lda()` と同じ

```
## データフレームを分析
require(MASS)
est <- qda(yの変数名 ~ x1の変数名 + ... + xpの変数名, data = mydata)
```

演習: 人工データによる2次判別

- 09-quad.r  を確認してみよう

多値判別

多値判別の考え方

- 判別関数の比較 (判別関数 δ_k を比較)
- 2値判別の統合 (組み合わせ数 ${}_nC_2$)
- $k - 1$ 個の特徴量への変換 (Rの線形判別)

変動の分解

- 3種類の変動の関係

- 全変動 : $A = \sum_{i=1}^n (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top$
- 群内変動: $W = \sum_{i=1}^n (\mathbf{x}_i - \mu_{y_i})(\mathbf{x}_i - \mu_{y_i})^\top$
- 群間変動: $B = \sum_{k=1}^K n_k (\mu_k - \mu)(\mu_k - \mu)^\top$
(n_k はクラス k のデータ数)

$$\text{全変動} A = \text{群内変動} W + \text{群間変動} B$$

Fisherの線形判別

- 特徴量 $Z = \alpha^\top X$
- 良い Z の基準:
 - クラス内では集まっているほど良い
 - クラス間では離れているほど良い
- Fisherの基準:

$$\text{maximize } \alpha^\top B \alpha \quad \text{s.t.} \quad \alpha^\top W \alpha = \text{const.}$$

Fisherの線形判別の解

- α は $W^{-1}B$ の最大固有値 (主成分分析の導出と同様)
 - $K = 2$ の場合:

$$\alpha \propto W^{-1}(\mu_1 - \mu_2)$$

(線形判別と一致する)

- 一般の K の場合: 第1から第 $K - 1$ 固有値を用いる
- 判別方法: 特徴量の距離を用いる
 - $d_k = \sum_{l=1}^{K-1} (\alpha_l^\top \mathbf{x} - \alpha_l^\top \mu_k)^2$ を計算
 - 最小の d_k となるクラス k に判別

演習: 3値判別の例

- [09-triple.r](#) を確認してみよう

演習: 多値判別の例

- [09-multi.r](#)を確認してみよう

演習: 実データによる例

- 以下のデータについて判別分析を行ってみよう
 - MASS::biopsy
 - MASS::crabs
 - rattle::wine